事前予約機構のポリシ記述による制御

中 田 秀 基[†] 竹房 あつ子[†] 大久保 克彦^{†,††} 工 藤 知 宏[†] 田 中 良 夫[†] 関 口 智 嗣 [†]

グリッド上の複数サイトにまたがるジョブの実行を実現する方法として、事前予約による同時確保がある。事前予約を実現するローカルスケジューラは、いくつか提案されているものの、事前予約ジョブと通常のジョブを共存させるための適切なポリシは明らかになっていない。われわれは、事前予約ジョブと通常ジョブ間のポリシは、各サイトのローカルスケジューラに内蔵されるべきではなく、管理者が設定するべき事項であると考え、実装中の PluS 事前予約機構に、管理者によるポリシ記述機能を組み込んだ。ポリシ記述には、Condor プロジェクトで用いられている ClassAd を用いた。我々は、1) ClassAd による記述力は管理ポリシを記述するのに十分であること、2) PluS の提供する情報により有効な管理ポリシが記述できること、3) ClassAd によるポリシ解釈のオーバヘッドは十分小さいことを確認した。

Policy-based Control of Advance Reservation

HIDEMOTO NAKADA ,† ATSUKO TAKEFUSA ,† KATSUHIKO OOKUBO,†,†† TOMOHIRO KUDOH ,† YOSHIO TANAKA † and SATOSHI SEKIGUCHI †

While advance reservation is the most promissing way to enable co-allocation of distributed resources over the Grid, and there are several local schedulers that provide such a capability, it is still a open problem that how to setup 'policies' for reservation, such as, 'should I accept this reservation request'? We claim that such a policy should not be embedded in the local schedulers, but should be able to be set by each site administrator. We implemented a policy evaluation capability in our PluS reservation manager to allow administrators to setup there own policy. As the policy language, we employed ClassAd which is developed as a part of the Condor Project. We confirmed that, 1) ClassAd is powerful enough to describe policies 2) Information provided by the PluS reservation manager is enough to describe meaningful policies 3) policy evaluation overhead is acceptable.

1. はじめに

グリッドの目的のひとつである複数サイトにまたがるジョブの実行を実現する方法として、事前予約による複数サイト上資源の同時確保がある。このためには、事前予約を実現するローカルスケジューラが必要となり、われわれの PluS を含めていくつかの事前予約機構が提案されている ^{1),2)}. ここで問題となるのは、ユーザ間のフェアシェアと予約ジョブと非予約ジョブの共存である。通常の非予約ジョブのみを対象とするローカルスケジューラでは、FCFS (First Comes First Served) ベースのスケジューリングに加え、なんらかのプライオリティとフェアシェアが実現されており、複数のユーザのジョブがバランスをもって実行

される枠組が整えられている. しかし, 事前予約ジョ ブに関してはこの種の枠組があるとはいえず,特に非 予約ジョブと混在した場合のポリシについては明確に なっていない. このため、現存する事前予約機構の多く は過度に保守的なポリシをとっている. 例えば、PBS Professional では、非予約ジョブがキューイングされ ていないノードに対してだけ予約ジョブを割り当てる. Catalina¹⁾ は、全てのジョブを予約ジョブ扱いとして ノードに事前配置した上で,空いたノードと時間帯が あれば、予約ジョブを受け付ける. しかし一般に、実 運用されているクラスタの多くは、稼働率100%に近 く,このようなポリシでは事前予約を実際にいれて複 数資源の同時確保を行うことはほとんど不可能である. これに対して、われわれが過去に提案した PluS 予約 機構 3),4) では、事前予約ジョブを最優先したポリシを 採用した. このポリシでは、予約は他の予約に干渉し ない限り必ず成功し, 予約開始時刻には実行中の非予 約ジョブをプリエンプトして予約ジョブを実行する.

[†] 産業技術総合研究所 National Institute of Advanced Industrial Science and Technology (AIST)

^{††} 数理技研 SURIGIKEN Co., Ltd.

このポリシは同時確保を最優先として考える場合には 有効であったが、通常のクラスタの運用ポリシとして は問題がある。また、ユーザ間のフェアシェア問題に 関してはなにも解決できていない。

われわれは、事前予約ジョブと通常ジョブ間のポリシは、事前予約システムに固定的に内蔵されるべきではなく、管理者が設定するべき事項であると考える。これを実現するためには、なんらかのポリシ記述言語を予約システムに内蔵し、管理者にポリシの記述を許す必要がある。

われわれは、実装中の PluS 事前予約機構に、ポリシ解釈機能を組み込んだ、ポリシ記述言語としては、Condor プロジェクト ^{5),6)} で開発され、Condor 内部のみならずいくつかのプロジェクトで使用されている ClassAd^{7),8)} を用いた、これによって、サイト管理者は、あるジョブ予約リクエストに対して任意のポリシを定義し、運用することができる。

本稿の構成を以下に示す。2節でベースとなる PluS 予約機構の概要を、3節で ClassAd の概要を示す。4節で ClassAd の PluS への組込みの詳細を述べる。5節で、ClassAd を用いたポリシ記述の例を示す。6節では、ClassAd を用いることによるオーバヘッドを評価する。7節はまとめである。

2. PluS の概要

PluSは、既存キューイングシステムである、TORQUE⁹⁾ および Grid Engine¹⁰⁾ に対してプラグインとして動作する事前予約機構である。キューイングシステムに対してプラグインする方法として、キューイングシステムの既存スケジューリングモジュールを完全に置換する方法と、キューを外部から制御することで予約を実現する方法の2つをサポートしている。予約操作に関して、2相コミットを実現している点も特徴である。

キュー操作法で運用する場合の PluS の構造を図 1 に示す. 灰色のモジュールは、キューイングシステムが提供するモジュールで、中央上部の「予約管理モジュール」が PluS の提供するモジュールである.

PluS は予約操作コマンドをユーザに提供する.キュー操作法では,個々の予約は個別のキューとして実現される.ユーザは,コマンドを利用して予約 ID を取得し,予約 ID を付記してジョブ投入を行う.通常のジョブ操作コマンドがキューイングシステムのマスタモジュールで処理されるのに対して,予約操作コマンドは,PluS の本体であるモジュールによって処理される.

PluS は,予約受けつけ時および予約開始/終了時刻に,一連のキュー操作コマンドをマスタモジュールに対して発行し,ジョブキューの作成,活性化,非活性化,破棄などの操作を行う.

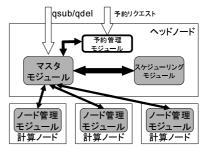


図1 PluS の構造

3. ClassAd の概要

3.1 ClassAd 言語

本節では、ポリシ記述に用いた ClassAd について 述べる。ClassAd は、新聞などに求職、求人などに分 類されて掲載される数行の広告を意味する Classified Advertisement の意である。Condor では、リソース やジョブがそれぞれの属性や要請を広告し、Negotiator と呼ばれるモジュールが、この情報を用いてリソー スとジョブを引き合わせることによってジョブに対す るリソースの割り当てを行っている。gLite^{11),12)} も 同様に、ClassAd を用いたリソース割り当てを行う。

言語としての ClassAd は以下の特徴を持つ.

- 逐次的ではなく宣言的な記述
- 副作用がない
- 評価にかかる時間が、式の長さに対して線形

ClassAd は動的にストリクトな型付けを行う. 基本型には、整数型、実数型、文字列、真偽値、時刻、相対時間が用意されており、この他に、エラーを表す Error、定義不能を示す Undefined がある. データ構造の型として、レコード型とリスト型がある. レコード型はキーワードと値のペアを格納する構造である. リスト型は任意の長さの値を列挙の格納する構造である. レコード型もリスト型も任意回数ネストすることができる.

図 2 に簡単な ClassAd の例を示す.全体を囲んだ大括弧 ('[]')が、レコード型を示している。bは、ネストしたレコードの定義である。cの定義の右辺に表れている中括弧 ('{}')はリスト型を示している。dの右辺はリスト型の要素に対する参照である。e はセレクションと呼ばれる操作で、レコードの内部を参照している。f の右辺は'isInteger' 関数を呼び出す関数呼出となっている。このデータ構造の抽象構文木を図3に示す。

ClassAd の評価は、各レコードをスコープとして変数の値を決めることで行う、スコープ (レコード) がネストしている場合は内側のスコープを優先して値を決定する。図 2 上段に示した ClassAd を評価した結果を図 2 下段に示す。b.g はa を参照しているが、こ

図2 ClassAd の例と評価結果

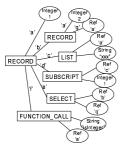


図3 抽象木

のaは、外側のレコードではなく、内側のレコードを 参照するため、1 ではなく 2 と評価されている.

3.2 ClassAd 処理系

ClassAd の処理系は、C++によるものと Java によるものが、Condor チームにより公開され、メンテナンスされている。これらの処理系には、独自記法および XML 記法のパーザ、アンパーザが含まれている。処理系はライブラリとして提供されているため、容易に他のシステムに組み込んで利用することができる。

ClassAd 処理系には、基本的な関数が組込み関数として含まれている。さらにユーザが独自に関数を定義して組み込むことも可能である。この場合、関数は処理系が記述されている言語 (C++もしくは Java)で記述する。

4. システムの設計と実装

4.1 要 請

以下に事前予約システムのポリシ記述に対する要請 をまとめる

- ユーザ間のフェアシェアを実現できる
- 事前予約ジョブと非予約ジョブの間のフェアシェアを実現できる
- 管理者が自由に設定できる
- ポリシ記述が直感的で再利用可能である
- ポリシの評価時間が、レスポンスタイムに大きな 影響を与えない

4.2 設 計

上記の要請を満たすために我々は下記の設計方針を 設定した.

- ポリシ判断に必要な様々な情報を可能な限り提供 する
- 記述力が高い宣言的言語を用いる

前者は、フェアシェアを実現するためである。フェアシェアを実現するためには、現在のジョブの情報を可能な限りポリシ判定部に提供し、判断の材料とする必要がある。後者は逐次的な言語では、記述によっては、極端に評価時間がかかってしまう場合があり、評価時間の見積りができなくなってしまう可能性があるためである。

われわれは ClassAd をポリシ言語に用いた. ClassAd は、評価時間が式の長さの線形時間に収まることが保証されている. また ClassAd ではレコードエントリの定義が、ユーザ定義関数的に機能するため、比較的見通しがよく再利用可能なポリシの記述が可能である.

4.3 実 装

ClassAd によるポリシ記述を可能にするために、PluS事前予約機構を改良した。管理者は、事前に ClassAd を利用して予約受け入れポリシをファイルに記述しておく。ポリシは、単一のノードに対するリクエストを受け入れるかどうかを真偽値で表現する式として記述する。

事前予約モジュールは、ユーザからの事前予約リクエストを受領すると、管理者の設定したポリシと、現在のノードおよびジョブ状態とリクエストを勘案して、その予約リクエストを受け入れるかどうかを判断する。具体的には、管理者の記述したポリシ ClassAd をファイルからロードし、これに、現在のノードおよびジョブの状態と、リクエストの情報を ClassAd レコードで表現したものをマージして、レコード中のPLUS_RESERVABLE_NODE を評価する。リクエストおよび状態を表現するために PluS が提供する変数を表 1に示す。

ClassAdによる判定は、個々の候補ノードに対して行う。まず、その予約時間帯に使用可能なノードのリストを作成し、その中のノードを、1つずつ可否の判定対象となるPLUS_CANDIDATE_NODEに設定し、ポリシ ClassAd を繰り返し評価する。このループは、リクエストされたノード数が予約可能と判定された時点で終了する。

各ノード情報は、ClassAdのレコードとして表現される。各レコードのメンバを表2に示す。ノード情報には、実行中のジョブを示すレコードのリストも含まれる。このレコードリストのメンバを表3に示す。ジョブ情報には、ジョブのオーナや開始時刻、walltimeなどの様々な情報が含まれている。

	表 1 名前	PluS が提供する変数 型	意味
	PLUS_RSV_OWNER	文字列	予約をリクエストしたユーザ
予約リクエスト情報	PLUS_RSV_START	絶対時刻	予約開始時刻
	PLUS_RSV_END	絶対時刻	予約終了時刻
内部状態	PLUS_ALL_NODES	ノードレコードのリスト	すべての実行ノードの情報
対象ノード	PLUS_CANDIDATE_NODE	ノードレコード	予約可能かどうかを判定する対象ノード
	PLUS_ALLOCATED_NODES	ノードレコードのリスト	すでに予約対象となったノードのリスト

表 2 ノード情報のレコードメンバ				
名前	型	意味		
name	文字列	ノードの名前		
isAlive	真偽値	実行デーモン稼動状況		
loadavg	実数	ノードのロードアベレージ		
nRunJobs	整数	実行中のジョブの数		
jobs	ジョブレコード	実行中のジョブ情報リスト		

のリスト

名前	表 3 ジョブ 型	「情報のレコードメンバ 意味
id	文字列	ジョブ ID
owner	文字列	ジョブオーナ名
state	文字列	ジョブ状態 (Queued, Running,
		Exiting, Held, Suspended)
priority	整数	プライオリティ
startTime	絶対時刻	開始時刻
wallTime	相対時間	walltime

```
UnusableNodes = {"unusableA", "unusableB" };

PLUS_NODE_RESERVABLE =
(PLUS_CANDIDATE_NODE.nRunJobs == 0 &&
PLUS_CANDIDATE_NODE.isAlive &&
PLUS_CANDIDATE_NODE loadavg <= 0.3 &&
!member(PLUS_CANDIDATE_NODE.name,
UnusableNodes));
```

図4 簡単なポリシの例

5. ポリシ記述例

PluS のポリシ記述力を示すために、いくつかのポリシのサンプルを示す.

5.1 簡単なポリシ

図 4 に,簡単なポリシの例を示す.この例では,使用不能なノードが 2 つある場合に("unusable A", "unusable B"),それ以外のノードから,稼働中で,実行中のジョブがなく,しかもロードアベレージが 0.3 以下のノードを探して利用するというポリシを記述している.

5.2 比較的複雑なポリシの例

図5に、ユーザのプライオリティと、予約開始時刻までの時間を考慮にいれた予約ポリシの例を示す。このポリシでは、VIPユーザ、一般ユーザ、低優先度ユーザの3種類のユーザを仮定している。VIPユーザ

```
MaxPeriod = relTime("00:30:00")
MinPeriod = relTime("02:00:00");
LimitPeriod = relTime("7d");
LimitPeriod = rellime("/d");
MaxReserveDuration = rellime("2d");
VIPs = { "userA", "userB", "userC" };
Users = { "userX" };
VIPRatio = 100.0;
UsersMaxRatio = 90.0;
UsersMinRatio = 50.0;
OthersMaxRatio = 50.0;
OthersMinRatio = 30.0:
MaxRatio = member(PLUS_RSV_OWNER, Users) ?
                                          UsersMaxRatio
                                          OthersMaxRatio:
MinRatio = member(PLUS_RSV_OWNER, Users) ?
UsersMinRatio :
                                          OthersMinRatio;
now = absTime(time());
prev = PLUS_RSV_START
                                   - now
duration = PLUS_RSV_END - PLUS_RSV_START;
ratioFunc = linear(prev, MaxPeriod, MaxRatio
                                       MinPeriod, MinRatio);
rsvRatio =
                       <= relTime("0")
    (prev
     LimitPeriod <= prev | | | duration >= MaxReserveDuration) ? 0 :
         member(PLUS_RSY_OWNER, VIPs) ? VIPRatio : (prev <= MaxPeriod) ? MaxRatio : (prev >= MinPeriod) ? MinRatio : ratioFunc;
nAllocate = size(PLUS_ALLOCATED_NODES) + 1;
nAllocatable =
size(PLUS_ALL_NODES) * 0.01 * rsvRatio
PLUS_NODE_RESERVABLE = (nAllocate <= nAllocatable)
```

図5 予約時刻までの時間とユーザのプライオリティを考慮したポリシの例

は空いた計算資源があれば常に予約を入れることができるが、一般ユーザは資源の5割まで、低優先度ユーザは資源の3割までしか利用できない。これは、後から VIP ユーザが予約を希望する場合に備えて、予約 スロットを確保するためである。ただし、予約時刻が直近である場合には、VIP ユーザが予約を希望する可能性が低くなったと考え、一般ユーザ、低優先ユーザの予約可能割合を増やす。これは、ホテルなどが VIP 用に確保している部屋を当日のとびこみ客に開放するのと同じ考えかたである。この例では、予約時刻の2時間前から、30分前にかけて線形に予約可能割合を増加させている。つまり、3時間前に予約を試みて失敗しても、30分前になれば予約が成功する可能性があるということである。図6に、各ユーザの予約可能割合の変化を示す。

5.3 ユーザの予約状況を参照するポリシ

図7に,ユーザの予約状況に応じて予約の可否を決 定するボリシを示す.この例では,現在時刻から7日

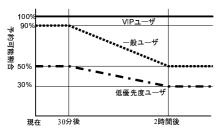


図 6 各ユーザクラスの予約可能割合

```
UtilCheckPeriod = relTime("7d");
MaxReserveCount = 100;
MaxReserveDuration = relTime("2d");
MaxReserveHourNode = 1000.0;

now = absTime(time());
util = plus_rsvutil(
    PLUS_RSV_OWNER,
    now - UtilCheckPeriod,
    now + UtilCheckPeriod);

PLUS_NODE_RESERVABLE =
    ((util[0] <= MaxReserveCount) &&
        (util[1] <= MaxReserveDuration) &&
        (util[2] <= MaxReserveHourNode));
```

図7 ユーザの予約状況に応じた判断の例

前から7日後までの当該ユーザの予約状況を参照し、それが設定した上限値を越えない場合にのみ予約を許している。ここで、plus_rsvutilは、予約状況を参照するために追加した組込み関数である。この関数は、引数に、ユーザ名と時間区間をとり、その間のユーザの予約状況をサマライズし、予約回数、予約時間の総計、予約ノード数と予約時間の積の総計を配列として返す。

5.4 実行中のジョブの実行を妨げないポリシ

PBS Professional などでは、実行中の非予約ジョブがある場合には、そのジョブの終了時刻までは、そのノードに対する予約を受理しない。図8に示す例は、このようなポリシを実現した例である。このポリシは、候補ノードで実行中のジョブを参照し、その終了時刻をwalltimeから推測して、その終了時刻が、予約開始時刻よりもあとである場合には予約リクエストを拒否する。

ここで用いられているevaluateList は、われわれが新たに追加定義したmap 高階関数に相当する組込み関数である。evaluateList は、第1引数にリストを、第2引数と第3引数に変数名をとり、第1引数のリストの内容をひとつずつ第2引数で指定された変数名にバインドして、第3引数で指定された変数を評価し、その結果で構成されるリストを返す。つまり第2引数を仮引数として,第3引数を関数として評価するのである。この例では、リストPLUS_CANDIDATE_NODE.jobs の内容をjobにセットし、それぞれに対してjobFinishTimeを計算している。

図8 実行中のジョブの実行を妨げないポリシ

6. 評 価

ポリシの評価によるオーバヘッドが予約機構のレスポンスタイムに与える影響を知るために、ポリシ Clas-sAd の評価の時間を計測した。ポリシがノード情報を参照する場合には、ポリシの評価時間がシステムに存在するノードの数、およびリクエストされたノードの数に依存することが予想されるため、これらの値を、1,10,100,1000 と変化させて計測した。

測定には PluS そのものを用いず, ClassAd の評価のみを行うモジュールを作成しそこで行った. これは, PluS 内部の他の部分に起因する変動から評価のオーバヘッドを切り分けるためである. ノードの情報は, ダミーの固定情報となっている.

測定環境には、Athlon 64 X2 2.0G、メモリ 4G、OS Fedora Core 6、Java 処理系 には Sun J2SE 1.5.0 を 用いた。計測は数百-数万回繰り返し、その平均値を算出している。繰り返し回数は、評価にかかる時間に応じて、それぞれ 1 秒程度経過するように調整している。 図 9、図 10 にそれぞれ、リスト図 4、図 5 に示した ClassAd の評価にかかった時間を示す。 X,Y,Z 軸すべて対数になっていることに注意されたい。

ClassAd の評価時間は、短い場合ではマイクロ秒のオーダであり、もっとも時間がかかっている場合でも100 ミリ秒に満たないことがわかる。この速度は予約インターフェイスの通信やデータベース更新、キュー制御の時間に比較すると無視できる範囲である。

グラフの傾向としては、図9は、要求ノード数に比例した時間がかかっているのに対して、図10では全ノード数に対して比例している。これは、前者の評価が必ず成功するため、要求ノード回数だけ評価を行った時点で評価が終了するのに対し、後者は必ず失敗するため要求ノード数によらず、全ノード数だけ評価を繰り返すためである。

このグラフからはわかりにくいが、図9の全ノード

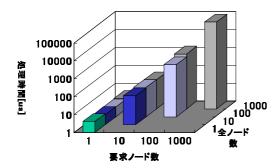


図9 図4に示した ClassAd の評価時間

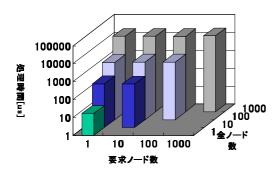


図 10 図 5 に示した ClassAd の評価時間

数が 1000 である場合の,要求ノード数に対する評価時間は,1,10,100,1000 に対して,3.9,43.0,1167.0,72897.8 [μs] と線形を逸脱して増加している.この原因は現在調査中であるが,なんらかのメモリマネージメントの問題である可能性があると考えている.

7. おわりに

事前予約リクエストを受理ポリシを管理者に記述させる枠組として、ClassAdを用いたポリシ評価機構を事前予約機構 PluS に組込んだ、いくつかの管理ポリシを示し、ClassAd の表現力と PluS の提供する情報とによって、有効なポリシ記述が可能であることを示した。さらに、管理ポリシの評価にかかる時間を測定し、管理ポリシの評価によるオーバヘッドが許容できる範囲であることを示した。

今後の課題は以下の通りである.

- 実環境での運用を通して、実際に管理者が求める ポリシが現在提示している情報と ClassAd の枠 組で記述可能であることを検証する必要がある.
- スケジューラが持つ情報をどこまで、どのように管理ポリシに対して開示するかを検討する。開示する事自体は容易であるが、詳細な情報を開示しても管理ポリシで解釈する手間がかかったり、ポリシ記述が煩雑になってしまっては意味がない。

ある程度抽象化した情報を提示する必要がある.

• 今回示したシステムで記述できる管理ポリシは、 リクエスト受理のポリシのみである。今後は、例 えば予約開始時刻に割り当てるノードの選択など、 より詳細なポリシを記述できるようにシステムを 拡張することを検討している。

謝辞

本研究の一部は,文部科学省科学技術振興調整費「グリッド技術による光パス網提供方式の開発」による.

参考文献

- Yoshimoto, K., Kovatch, P. and Andrews, P.: Co-scheduling with User-Settable Reservations, Job Scheduling Strategies for Parallel Processing (Feitelson, D. G., Frachtenberg, E., Rudolph, L. and Schwiegelshohn, U.(eds.)), Springer Verlag, pp. 146–156 (2005).
- 2) Maui Cluster Scheduler. http://www.clusterresources.com/pages/ products/maui-cluster-scheduler.php.
- 3) 中田秀基, 竹房あつ子, 大久保克彦, 工藤知宏, 田中良夫, 関口智嗣: グローバルスケジューリング のための計算資源予約管理機構, HPCS 2007 予稿集, pp. 127–134 (2007).
- 4) Nakada, H., Takefusa, A., Ookubo, K., Kudoh, T., Tanaka, Y. and Sekiguchi, S.: An Advance Reservation-Based Computation Resource Manager for Global Scheduling, *Third Workshop on Grid Computing and Applications* (to appear).
- 5) Condor. http://www.cs.wisc.edu/condor/.
- 6) Livny, M., Basney, J., Raman, R. and Tannenbaum, T.: Mechanisms for High Throughput Computing, *SPEEDUP Journal*, Vol. 11, No. 1 (1997).
- 7) Raman, R., Livny, M. and Solomon, M.: Matchmaking: Distributed Resource Management for High Throughput Computing, *Proc.* of HPDC-7 (1998).
- Solomon, M.: The ClassAd Language Reference Manual. http://www.cs.wisc.edu/condor/classad/.
- 9) TORQUE Resource Manager. http://www.clusterresources.com/pages/ products/torque-resource-manager.php.
- 10) Grid Engine. http://gridengine.sunsource.net.
- 11) gLite: Lightweight Middleware for Grid Computing. http://glite.web.cern.ch/glite/.
- 12) EGEE Middleware Architecture and Planning, Technical Report DJRA1.4, EU Deliverables.