ポータビリティの高いジョブスケジューリングシステム設計と実装

町 田 悠 哉 中 田 秀 基 が 松 岡 聡がけ

グリッド環境に存在する不安定性と非均質性という2つの特徴に対応したジョブスケジューリングシステム Jay について述べる. Jay はウィスコンシン大学で開発されたスケジューリングシステム Condor の構造をベースとし、ポータビリティを高めるため Java で実装を行った. ここで Java にはプロセスのユーザ ID を安全に変更する手法がないという問題が生じたが、JNI をサポートしていない Java 環境においても稼働するようなポータブルな C++デーモンを開発することでこの問題に対処した. 小規模環境における評価実験により、本システムが耐故障性と高いポータビリティを備えていることが示された.

Design and Implementation of a Highly Portable Job Scheduling System

YUYA MACHIDA,† HIDEMOTO NAKADA****† and SATOSHI MATSUOKA*****†

We present a job-scheduling system for the Grid, Jay. Jay handles two difficulties inherent in the Grid: namely heterogeneity and instability. Jay is based on the techniques of Condor, which was developed at the University of Wisconsin, and has been implemented in Java for better portability. Although Java does not have a secure way of changing user IDs of an arbitrary process, we resolved the problem in Jay by developing a highly-portable C++ daemon that achieves this property and can run in Java environments that does not support JNI. The results of small-scale experiments show its fault-tolerance and high portability.

1. はじめに

広域ネットワーク上に分散した多数の計算資源を統合し、仮想的に高性能な計算機を構築するグリッドとだり、仮想的に高性能な計算機を構築するグリッドとなが普及しつつある。このようなグリッドシステムは、ユーザの大規模な計算要求を満たす技術であり、概して長期間に渡る計算を必要とするなジョブを対象としている。そのため、サブミットされたジョブが終了するまで計算に関わるマシンやネットワークなどすべてのエンティティが障害を起い、トされたジョブが終了するまで計算に関わるマシンやネットワークなどすべてのエンティティが障害を起けれたがいるという保証はなく、実実行に動作し続けるという保証はなく、実実行の計算資源が統合されたグリットウェア的にもハードウェア的にもハードウェア的にもハードウェア的にもハードウェア的にもハードウェア的にもハードウェアの計算資源を統一することは不可能であり、非均でな環境と考えなければならない。したがってグリット環境においてユーザに有用なジョブスケジューリン

グシステムを構築するためには耐故障性と高いポータ ビリティは欠くことのできない要素である.

耐故障性を備えたシステムの例として Condor^{1)~3)} がある. Condor にはチェックポイントやプロセスマイグレーションなどの機能を備えており、広く普及しているシステムである. しかし、Condor では、特定のプラットフォームしかサポートされておらず、ソースが非公開であるため、ジョブスケジューリングシステムの研究基盤としては利用することができない.

そこで、本稿では、耐故障性を備えた Condor の構造をベースとし、ポータビリティの高いジョブスケジューリングシステム Jay の設計・実装について述べる。本システムはポータビリティを高めるため Javaで実装を行った。しかし、Java ではプロセスのユーザ ID を変更することが不可能になるという弊害が生じた。そこで C++で記述されたデーモンを用意することでこの問題に対処した。Jay の有効性を示すため、長時間の計算を必要とするジョブをサブミットし、計算途中でリブートなどの外乱を与えたが、プログラムは無事終了し、小規模環境における耐故障性が示された。また、多少のコード修正で異なるアーキテクチャ上でもシステムが稼働することを確認し、ポータビリティの高さが示された。

Tokyo Institute of Technology

†† 産業技術総合研究所

National Institute of Advanced Industorial Science and Technology

††† 国立情報学研究所

National Institute of Infomatics

[†] 東京工業大学

2. Condor の概要

Condor はウィスコンシン大学で開発されたジョブスケジューリングシステムである. Condor では、ハイスループットコンピューティングの実現を目指しており、計算資源の遊休時間をいかに効率的に利用できるかが鍵となる.

Condor ではサブミットされたジョブを実行するマシンの集合を Condor プールと呼ぶ、Condor プールにはセントラルマネージャーと呼ばれるマシンが 1 台存在し、実際のスケジューリングを担当する。ユーザが Condor プールにジョブをサブミットするとジョブの情報はセントラルマネージャーに送信される。また、Condor プール内の各マシンもマシンのモニタリング情報をセントラルマネージャーに送信する。セントラルマネージャーに送信されるジョブやマシンの情報は ClassAd $^{4),5}$)と呼ばれるデータとして扱われる。セントラルマネージャーは回収した ClassAd に対してマッチメイキングと呼ばれる操作を行い、各ジョブに適したマシンが割り当てられる。

またサブミットするプログラムを Condor システム コールライブラリとリンクさせておくことにより、ジョ ブは計算の実行中に定期的にチェックポイントが取ら れ、チェックポイントファイルがクライアントのローカ ルディスクもしくは専用のチェックポイントサーバー に保存される. 実行マシンがクラッシュした場合は, 他のマシンでチェックポイントファイルからジョブを 再開することが可能で、それまでの計算が無駄になる のを防ぐことが可能である。また、プライオリティの 高いジョブがサブミットされた際にプライオリティの 低いジョブのチェックポイントを取り、他のマシンへ マイグレーションさせることも可能である、サブミッ トするプログラムは必ずしも Condor システムコール ライブラリとリンクさせる必要はないが、その場合に はチェックポイントは取られず、マシンのクラッシュ 時などには最初から計算が実行される.

3. Jav の設計

3.1 システムの要件と設計方針

グリッド環境には不安定性・非均質性という2つの特徴がある. そこで, これらの特徴に対処するためシステムを設計する際の要件として耐故障性と高いポータビリティが挙げられる.

まず、耐故障性については、マシンのクラッシュなどの障害により、サブミットされたジョブの情報が失われることを避けなければならない。これが保証されていないシステムでは、ユーザは常に自分がサブミットしたジョブのモニタリングを続け、計算結果を受け取る前に障害が発生した場合には、再びジョブをサブミットしなければならない。これを避けるためにサブ

ミットされたジョブの情報はファイルなどの永続性がある資源に (コンシステントな) 状態を常に保持しておき、障害が起きたとしてもそのファイルから障害発生前の状態に復旧できるようにしておく必要がある. また,ハードウェア的には正常に動作しているにも関わらず,ソフトウェア的な障害によりデーモンが落ちてしまい,システムが稼働しなくなるという事態も避けなければならない. このような障害を防ぐため,デーモン群を監視するデーモンを用意することにより,耐故障性の向上をねらう. また,ポータビリティに関しては,プラットフォームに依存しないように Java で実装を行い,高移植性の実現を目指す.

3.2 システムの概要

図1に本システムの概要を示した。本システムの基本的な構造は Condor を参考として設計されている。各マシンは以下に示す3種類の役割を担う。ただし、単一のマシンが複数の役割を担うこともある。

- サブミットマシン
- 実行マシン
- セントラルマネージャー

サブミットマシンはサブミットされたジョブの情報 の管理を行い、セントラルマネージャーから通知され た実行マシンにジョブの実行を依頼する. ジョブがサブ ミットされるとサブミットマシンはジョブ情報を取り 出し、このマシンが管理するキューに格納する. キュー 内のジョブ情報は定期的にセントラルマネージャーに 送信される. また、キューに格納されたジョブ情報は ファイルに書き出され、ジョブ情報に変更があった場 合には、その変更情報がファイルに追記される、そし てジョブが終了するとそのジョブ情報がキューから削 除され、ファイルにも終了したことが追記される、こ れにより、ユーザはつねにマシンやジョブ状態の監視 を続けなければいけないという状態から解放される. サブミットマシンはクラッシュなどが発生し、キュー 内の情報を失ったとしても書き出しておいたファイル を解析し、クラッシュ前のキュー状態に復元すること が可能となる.

実行マシンはマシン情報の管理を行い、サブミットマシンから依頼されたジョブを実行し、終了するとその結果を返す。マシン情報にはこのマシンのアーキテクチャやOS、メモリなどの情報の他にマシンの所有者により定義された利用ポリシーも含まれており、利用ポリシーを満たしたジョブのみがこの実行マシンで実行される。このマシン情報は定期的にセントラルマネージャーに送信される。

セントラルマネージャーはマシン情報やジョブ情報を基にスケジューリングを行うマシンであり、必ず 1 台のマシンをセントラルマネージャーとして用意する必要がある。セントラルマネージャーはマシン情報やジョブ情報を基に各ジョブを実行するのに適当なマシンを割り当てる作業 (マッチメイキング^{4),5)}) を定期的

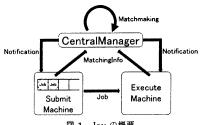


図 1 Jay の概要

に行う. Jay システムでは、ユーザごとにプライオリ ティが管理されており、プライオリティに応じて公平 にマシンが割り当てられる.

セントラルマネージャーはステートレスな情報管理 を行っており、サブミットマシンや実行マシンは、セ ントラルマネージャーの状態に依存せず、ジョブやマ シン情報を定期的に送信する. これにより, セントラ ルマネージャーがクラッシュした場合などに再起動後, 迅速にクラッシュ前のシステム状態に戻すことが可能 となる. また, すべてのマシンにおいて稼働デーモン を監視するデーモンが用意されているため、可能な限 りシステムが自律的に復旧できるようになっている.

4. Jay の実装

ここでは、Jay の実装について述べる.

4.1 デーモン

機能に応じて以下の5つのデーモンに分類する.

Master Master デーモンはすべてのマシンにおい てマシン起動時に稼働を開始し、他の必要なデー モンを起動する. また, 定期的に他のデーモンが 稼働しているかチェックし、止まっている場合に は,再起動を行う.

Collector Collector デーモンはセントラルマネー ジャーで稼働しており、ジョブやマシンの情報を 回収し、キューに格納する. Negotiator からリク エストが来ると、キュー内の情報を Negotiator に 送信する.

Negotiator Negotiator デーモンはセントラルマ ネージャーで稼働しており、Collectorから情報 を受け取り、それをもとにマッチメイキングを行 う. マッチメイキングが完了すると該当するマシ ンの Schedd と Startd に通知を行う. それ以降 のジョブ実行には関わることはない.

Schedd Schedd デーモンはサブミットマシンや実行 マシンで稼働しており、ジョブがサブミットされ るとキューに格納し, 各ジョブの情報をファイル に書き出す. 定期的にキュー内のジョブの情報を Collector に送信する. Negotiator から通知が来 ると Shadow を起動する. Shadow は Negotiator から通知されたマシンの Startd にジョブの実行

```
Job
MyType
                   "Machine"
TargetType
                   "sim"
Cmd
                   out"
Out
                   "err"
Err
                   "INTEL"
Arch
                   "LINUX"
OpSvs
                  (Target.Arch == "INTEL")
Requirements
                  && (Target.OpSys == "LINUX")
```

図 2 ジョブの MatchingInfo の例

```
Machine
MyType
                   "Job"
TargetType
Memory
                  256
                   "output"
Out
                  100000
Args
                  "smith"
Owner
                  (Target.Arch == "INTEL")
Requirements
                  && (Target.OpSys == "LINUX")
Rank
                  Target.Memory
```

図3 マシンの MatchingInfo の例

を依頼する. ジョブの実行が終了するとそのジョ ブの情報をファイルとキューから削除する.

Startd Startd デーモンは実行マシンで稼働してお り, 定期的にマシンの状態を調べ, マシンオーナー の設定ポリシーとともにマシン情報を Collector に定期的に送信する. Shadow からジョブの実行 を依頼されるとそのジョブが実行できる状態にあ るかを調べ、起動できる場合には Starter を起動 する. Starter は Shadow から依頼されたジョブ を実行し、結果を返す.

これらのデーモンはセキュリティ基盤として Globus Toolkit⁶⁾ ∅ GSI(Grid Security Infrastructure)^{7),8)} を Java Cog Kit 1.1⁹⁾ 経由で利用している.それに 対して Condor のデーモンは基本的に IP アドレスを ベースとして相互認証を行っている. しかし, IP ア ドレスは詐称可能であり、セキュリティ基盤としては 不十分である. GSI を導入した本システムは、より グリッド環境に適したセキュアなシステムであると言 える.

4.2 MatchingInfo

ジョブやマシンに関する情報は MatchingInfo とし て送受信を行う. MatchingInfo は, 属性名と属性値 のリストであり、Condor における ClassAd に相当 するものである. 図 2 にジョブの, 図 3 にマシンの MatchingInfo の例を示す. Requirements や Rank 属 性により、柔軟なスケジューリングが可能となる.

4.3 実装における問題点とその対処法

ここでは、Java で実装を行うことにより生じる問 題点とその対処法について述べる.

4.3.1 問題点

Java を使うことによる弊害は、Java がプラットフォーム間の完全な互換性を保つため一部の OS 機能をサポートしていないことである。その中にはsetuid/seteuid によるユーザ ID の変更機能が含まれている。これにより、ジョブはサブミットしたユーザとは異なるユーザ ID で実行されることになり、ファイルへのアクセスが制限されてしまう。

また, このユーザ ID の変更は慎重に行わなければ, 任意のユーザを詐称される危険性を含んでおり, セキュリティの確保が必須の要素である.

4.3.2 対 処 法

Javaではセキュアかつポータブルにユーザ ID を変更できないという問題に対処するため、本システムでは、C++で記述されたデーモンを用意することにより対処する。このデーモンは、すべてのマシンで稼働しており、任意のユーザ ID でジョブを起動し、監視するという作業を担当する。

Kickd デーモンを稼働させるため、本システムでは、システム稼働用の特別なユーザアカウント (jay とする)を用意しなければならない。Jay のデーモン群はこの jay アカウントで起動される。そして Kickd デーモンは jay からの要求のみ受け付けるようにする。Kickd デーモンは root アカウントで起動されるが、起動直後に seteuid システムコールを用いて実効 ユーザ ID を jay にして稼働する。プロセスの起動要求が来ると、認証完了後、まず seteuid システムコールで 実効ユーザ IDを root に戻し、その状態でプロセスを fork、直後に 実効ユーザ IDを jay に再セットする。子プロセス側では setuid システムコールで 実ユーザ ID を要求されたユーザ ID にセットして実行する。

Kickd デーモンでは図4のように認証を行う.まず、プロセスの起動要求が来るとある名前のファイルを作るように指示する.要求側は指示通りにファイルを作り、OK メッセージを送る. Kickd デーモンは OK メッセージを受け取ると作成するように指示したファイルの所有者を調べ、所有者が jay の場合のみ要求通りにプロセスの起動を行う.このように Kickd デーモンでは、ポータビリティと簡便性のために、ファイルベースでの認証作業を行っているが、将来的には GSI による認証も導入する予定である.

4.3.3 課 題

Kickd デーモンの導入により Java 実装による問題 点は解決されるが、Kickd デーモンは root 権限で起動しなければならないので Master デーモンの管理下にはない。そのため Kickd デーモンが落ちた場合にはそのマシンではジョブが実行されなくなるという問題がある。この点については今後の課題として挙げられる。また、Java Native Interface(JNI) を用いて Java で setuid を行うという代替案も考えられる。

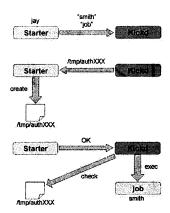


図 4 Kickd デーモンにおける認証

これにより容易にユーザ ID の変更が可能となるが、 ユーザ ID 変更部分を切り出し、認証を行うなどの手 法により慎重にセキュリティを確保する必要がある。

4.4 ジョブ実行の流れ

ジョブがサブミットされてからジョブが終了するまでの流れを説明する (図 5). 実際にジョブをサブミットする際には図 6 のようなサブミットファイルを用意する必要がある.

- StartdがマシンのMatchingInfoをCollector に送信する
- (2) ジョブがサブミットされる
- (3) Schedd がサブミットファイルを解析し、ジョ ブの Matching Info を作り、キューに格納する とともにジョブ情報をファイルに書き出す.
- (4) ScheddがジョブのMatchingInfoをCollector に送信する
- (5) NegotiatorがCollectorにリクエストを送信する
- (6) Collector が Negotiator に MatchingInfo を送信する
- (7) Negotiator は受け取った MatchingInfo をも とにマッチメイキングを行う
- (8) マッチメイキングによりペアになったマシンに 通知を送る
- (9) Schedd は Negotiator から通知が来ると Shadowを起動する
- (10) Shadow は Startd にジョブが実行できるかを 問い合わせる
- (11) Startd は Shadow からの依頼に返信する
- (12) Startd は Shadow からの依頼を受け付ける場合, Starter を起動する
- (13) Shadow は Startd から ('OK') メッセージを受け取るとジョブの起動に必要な情報を Starter に渡す
- (14) Starter がジョブを実行する
- (15) ジョブの実行が終了すると Shadow に実行結果

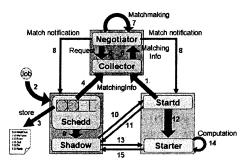


図 5 ジョブ実行の流れ

executable	=	sim
arguments	=	100
output	=	out.\$(Process)
error	=	err.\$(Process)
rank	=	Memory
requirements	=	(Arch == ''INTEL'')
		&& (OpSys == ''LINUX'')
queue 100		

図 6 サブミットファイルの例

表 1 実験環境			
CPU	Athlon MP 1900+ × 2		
Memory	768MB DDR		
Network	100Base-T		
OS	Linux 2.4.18		
Java	Sun JDK 1.4.2_03		

を返す

本システムは現時点ではまだ機能も限定されている という理由もあるが、約1万行程度のコードで非常に コンパクトに構成されており、改変も容易である.

5. 評価実験

5.1 耐故障性

まず本システムの耐故障性について評価を行う.

5.1.1 評価環境

実験には東工大松岡研究室のクラスタ PrestoIII の 10 ノードを使用した. ノードのスペックを表 1 に 示す. 1 ノードをセントラルマネージャーとし, 残り 9 ノードを実行マシンとした.

5.1.2 手 順

長時間の計算が必要なジョブとしてモンテカルロ法を用いて円周率を求めるプログラムを使用した。このプログラムは正方形に乱数で 2×10^9 個の点を生成し、それが正方形に内接する円に含まれるかどうか調べ、生成した点の数と円内に含まれる点の数との比から円の面積を求め、その値から円周率を計算する。表 1 のマシンでは約1時間の実行時間を要する。このようなジョブを実行マシンの 1 台から 50 個サブミットした。

長時間の実行中に以下のような外乱を故意に与える ことにより、本システムの耐故障性を検証した.

- (1) 開始約50分後実行マシンの1つをリブート
- (2) 開始約90分後1つの実行マシンの Startd プロセスを停止
- (3) 開始約130分後セントラルマネージャーをリブート
- (4) 開始約170分後実行マシンの1つをリブート
- (5) 開始約210分後1つの実行マシンの Startd プロセスを停止
- (6) 開始約275分後サブミットマシンをリブート

5.1.3 評価結果

図7に実行中のジョブの数の推移を示す.約1時間 ごとにジョブが終了し、次のジョブがスケジューリングされていることがわかる.また、外乱を与えた時間 にジョブが停止し、その後、再実行されていることも わかる.サブミットされたジョブは約6時間後にすべて終了し、本システムが耐故障性を備えていることが確認された.より大規模で実際のアプリケーションでの実験については今後の課題とする.

5.2 ポータビリティ

本システムは x86 Linux 2.4.19 上で開発を行った が、ポータビリティの検証のため、SPARC SunOS 5.8 に移行を行った. 本システムが稼働するために必要な 修正点は Master デーモンでデーモンの稼働状況を確 認する際に使用する ps コマンドのオプションとマシ ンのメモリ情報を確認する際に使用する free コマン ドだけである. このようなマシン依存部分が今後増え ないという保証はないが、プロセスの確認部分やマシ ン情報のモニタリング部分というように簡単に切り分 けが可能で容易に移行が可能であると考えられる。ま た, C++で記述された Kickd は, プロセスの実効ユー ザ ID を変更するという必要最低限の機能のみを提供 するコンパクトなプログラムなのでプラットフォーム に依存しておらず、ソースを改変せずにコンパイルを すればよい、以上より、本システムのポータビリティ の高さが確認されたが、今後、他のさまざまなプラッ トフォームにおける検証も必要である.

6. おわりに

6.1 ま と め

本稿では、グリッド環境に適応するため、耐故障性およびポータビリティを備え、研究基盤として利用可能なスケジューリングシステム Jay の設計と実装について述べた。本システムは Condor を規範とし、ジョブ情報のファイルへの書き出しやデーモンを監視するMaster デーモンにより耐故障性を提供している。また、ポータビリティを高めるため、Java で実装を行い、それにより生じる問題点についても C++で記述された Kickd デーモンを用意することで解決した。

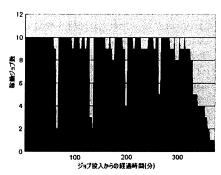


図7 稼働ジョブ数の推移

本システムの耐故障性を確認するため、長時間の計算を必要とするジョブをサブミットし、故意にマシンをリブートするなどの外乱を与えた.その結果、すべてのジョブが無事終了し、耐故障性が備わっていることを確認した.また、本システムを異なるプラットフォームに移行を行い、ポータビリティの高さについても確認できた.

6.2 今後の課題

今後の課題として以下が挙げられる.

- Condor との比較 ポータビリティや認証,互換性などを含めて Condor と比較を行う必要がある.
- 大規模環境での実験 セントラルマネージャーにおけるマッチメイキン グや認証などがボトルネックとなることはないか, より大規模なグリッド環境での実験を行い,シス テムのスケーラビリティを確認する必要がある.
- 複数のチェックポインタのポータブルな導入フレームワーク 実行マシンがクラッシュした場合などは、それまでの計算結果が失われてしまい、一から計算をやり直さなければならないので、既存のチェックポインタを利用してそれに対応する必要がある。これによりプロセスマイグレーションも可能となる。この際に、実行プラットフォームによってチェックポインタが用意されている場合は、それを直接利用するようなポータビリティの高いフレームワークが必要である。
- プライベートアドレスへの対応 現在、本システムはプライベートアドレス空間に は対応していないので、UPnP を含み、さまざま な手法に対処できる必要がある。
- データインテンシブなアプリケーションへの対応 入出力データのサイズが大きい場合、実行マシン は計算以外のデータ転送に時間を浪費してしまう。 Condorでは、Stork¹⁰⁾というデータスケジュー リングシステムを用いて対応している。しかし、 Condorと Stork は、独立にスケジューリングを

行っており、最適なスケジューリングを行っているとは言えない. そこで本システムでは、複製管理システムと連携し、複製に関する情報も回収した上でマッチメイキングを行うことでより最適なスケジューリングが可能になると考える.

謝辞 本研究は、科学技術振興機構・計算科学技術 活用型特定研究開発推進事業 (ACT-JST) 研究開発課 題「コモディティグリッド技術によるテラスケール大 規模数理最適化」の援助による。

参考文献

- 1) Condor Project Homepage, http://www.cs.wisc.edu/condor/.
- Litzkow, M., Livny, M., and Mutka, M.: Condor A Hunter of Idle Workstations, Proceedings of 8th International Conference of Distributed Computing Systems, pp. 104-111 (1988).
- Epema, D., Livny, M., Dantzig, R., Evers, X. and Pruyne, J.: A Worldwide Flock of Condors: Load Sharing among Workstation Clusters, Journal on Future Generations of Computer Systems, Vol. 12 (1996).
- 4) Livny, M., Raman, R. and Tannenbaum, T.: Mechanisms for High Throughput Computing, SPEEDUP Journal, Vol. 11, No. 1 (1997).
- Raman, R., Livny, M. and Solomon, M.: Matchmaking: Distributed Resource Management for High Throughput, Proceedings of 7th IEEE International Synposium on High Performance Distributed Computing, July 28-31 (1998).
- Foster, I. and Kesselman, C.: Globus: A Metacomputing Infrastructure Toolkit, Internatinal Journal of Supercomputer Applications, 11(2):115-128 (1997).
- Foster, I., Kesselman, C., Tsudik, G. and Tuecke S.: A Security Architecture for Computational Grids, Proceedings of 5th ACM Conference on Computer and Communications Security Conference, pp. 83-92 (1998).
- 8) Welch, V., Foster, I., Kesselman, C., Mulmo, O., Pearlman, L., Tuecke, S., Gawor, J., Meder, S. and Siebenlist, F.: X.509 Proxy Certificates for Dynamic Delegation, 3rd Annual PKI R&D Workshop (2004).
- 9) Java Cog Kit 1.1, http://www.globus.org/cog/java/1.1/.
- 10) Kosar, T. and Livny, M.: Stork: Making Data Placement a First Class Citizen in the Grid, Proceedings of 24th IEEE International Conference on Distributed Computing Systems (ICDCS2004), Tokyo, Japan.